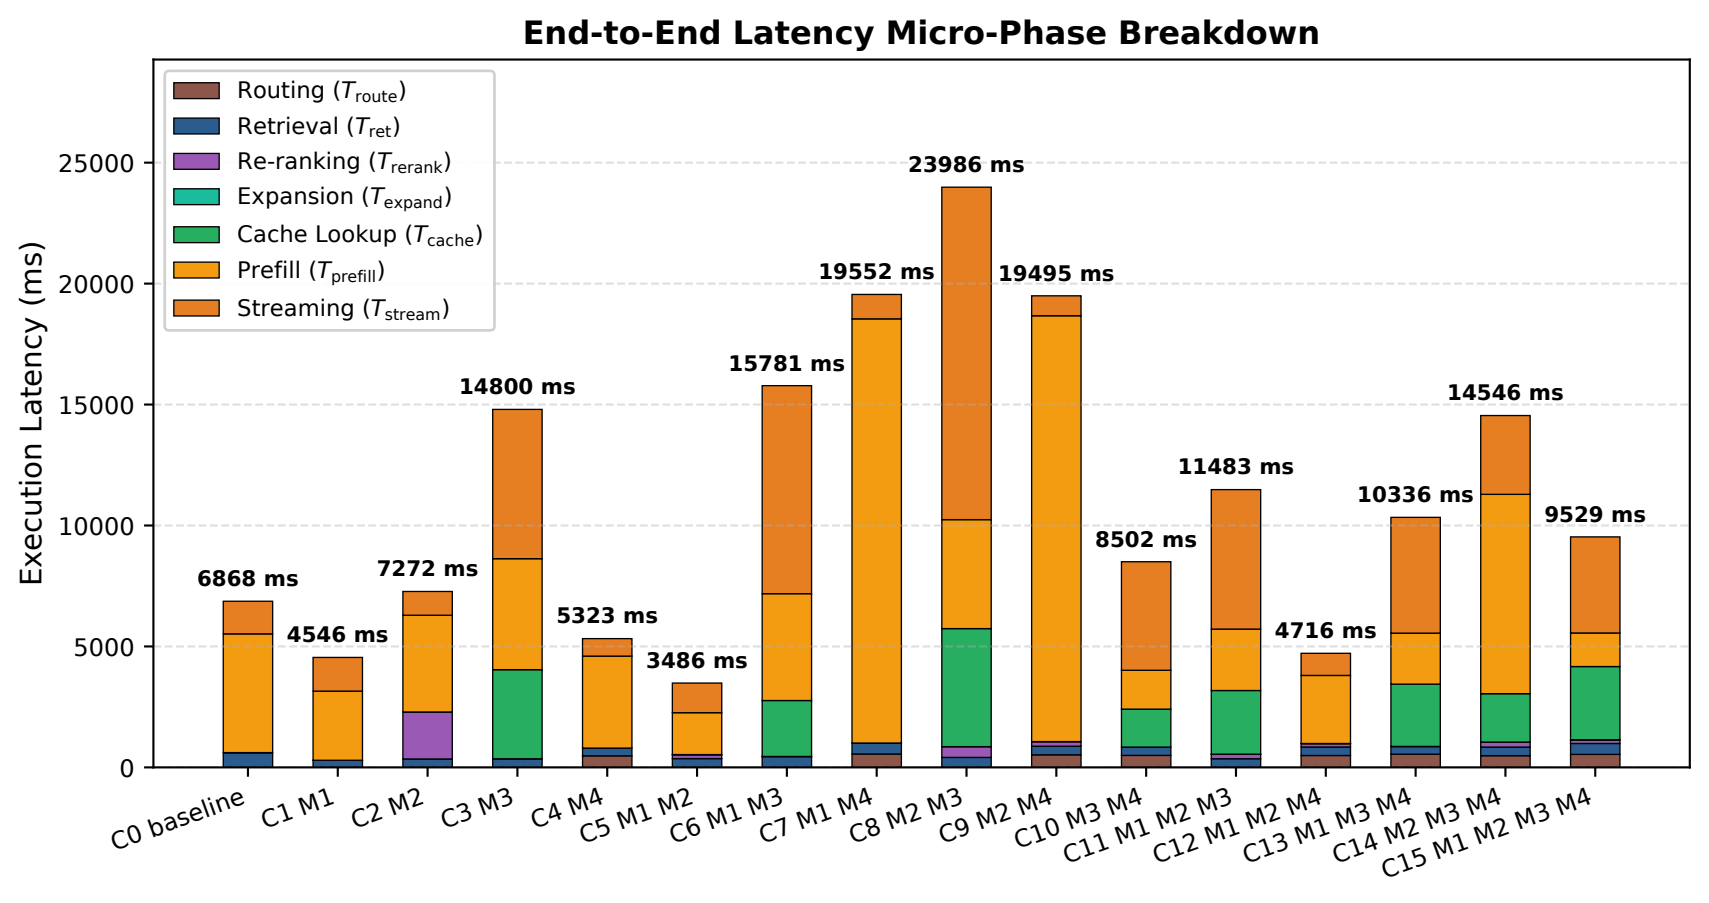
End-to-End Latency Micro-Phase Breakdown
Routing (T_{route})
Retrieval (T_{ret})
Re-ranking (T_{rerank})
Expansion (T_{expand})
Cache Lookup (T_{cache})
Prefill ($T_{prefill}$)
Streaming (T_{stream})
Execution Latency (ms)
0
5000
10000
15000
20000
25000
6868 ms
4546 ms
7272 ms
14800 ms
5323 ms
3486 ms
15781 ms
19552 ms
23986 ms
19495 ms
8502 ms
11483 ms
4716 ms
10336 ms
14546 ms
9529 ms
C0 baseline
C1 M1
C2 M2
C3 M3
C4 M4
C5 M1 M2
C6 M1 M3
C7 M1 M4
C8 M2 M3
C9 M2 M4
C10 M3 M4
C11 M1 M2 M3
C12 M1 M2 M4
C13 M1 M3 M4
C14 M2 M3 M4
C15 M1 M2 M3 M4