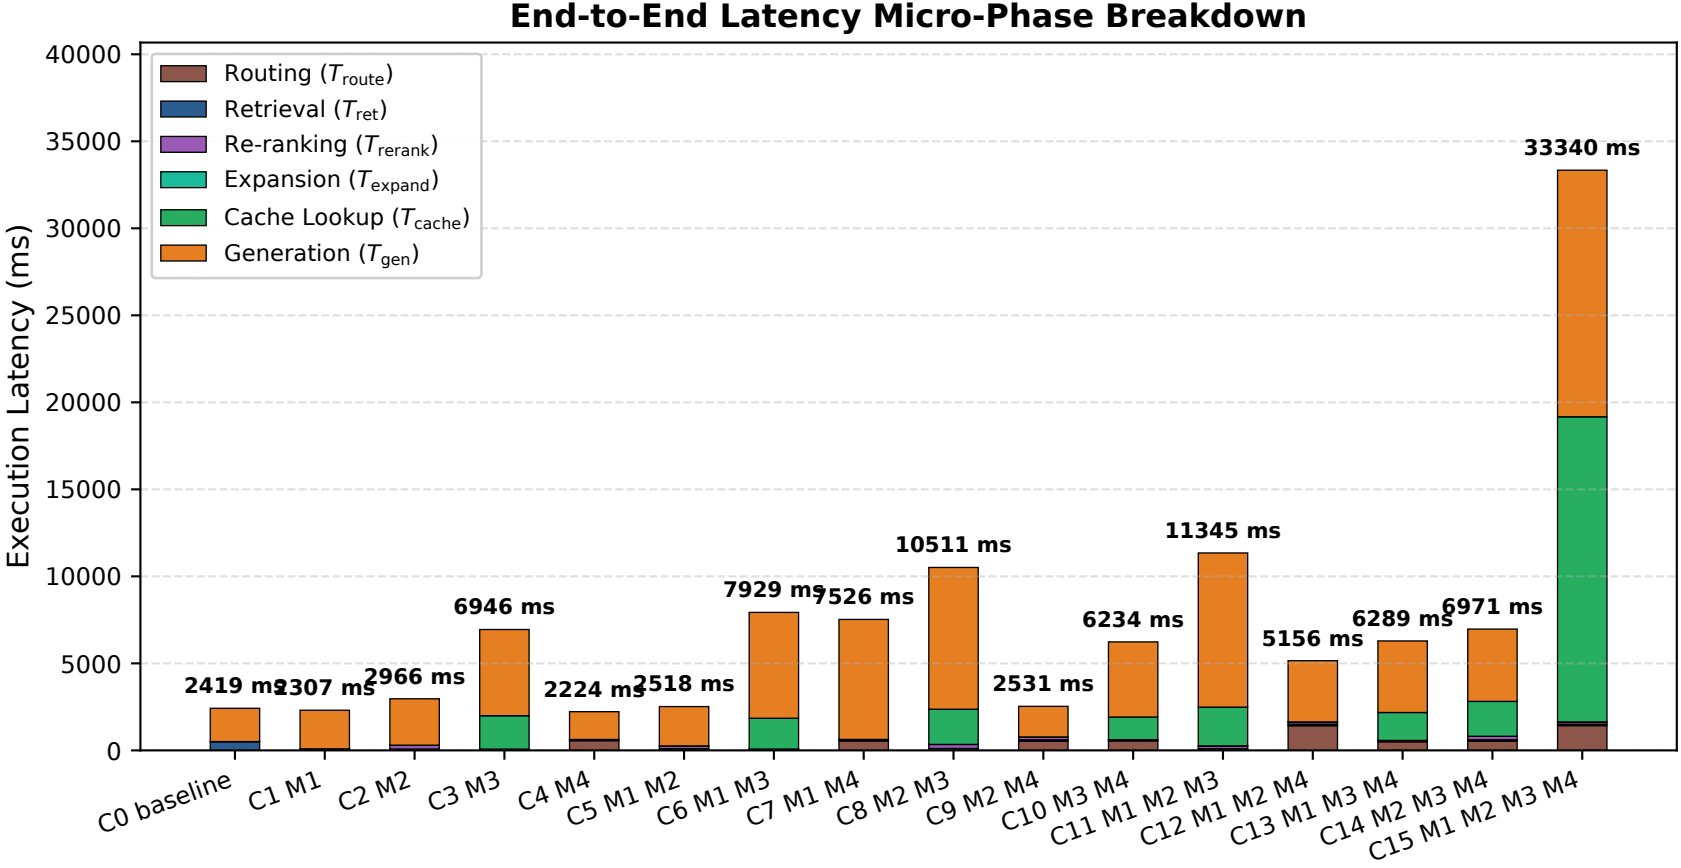
End-to-End Latency Micro-Phase Breakdown
Execution Latency (ms)
Routing (T_{route})
Retrieval (T_{ret})
Re-ranking (T_{rerank})
Expansion (T_{expand})
Cache Lookup (T_{cache})
Generation (T_{gen})
2419 ms
2307 ms
2966 ms
6946 ms
2224 ms
2518 ms
7929 ms
7526 ms
10511 ms
2531 ms
6234 ms
11345 ms
5156 ms
6289 ms
6971 ms
33340 ms
C0 baseline
C1 M1
C2 M2
C3 M3
C4 M4
C5 M1 M2
C6 M1 M3
C7 M1 M4
C8 M2 M3
C9 M2 M4
C10 M3 M4
C11 M1 M2 M3
C12 M1 M2 M4
C13 M1 M3 M4
C14 M2 M3 M4
C15 M1 M2 M3 M4