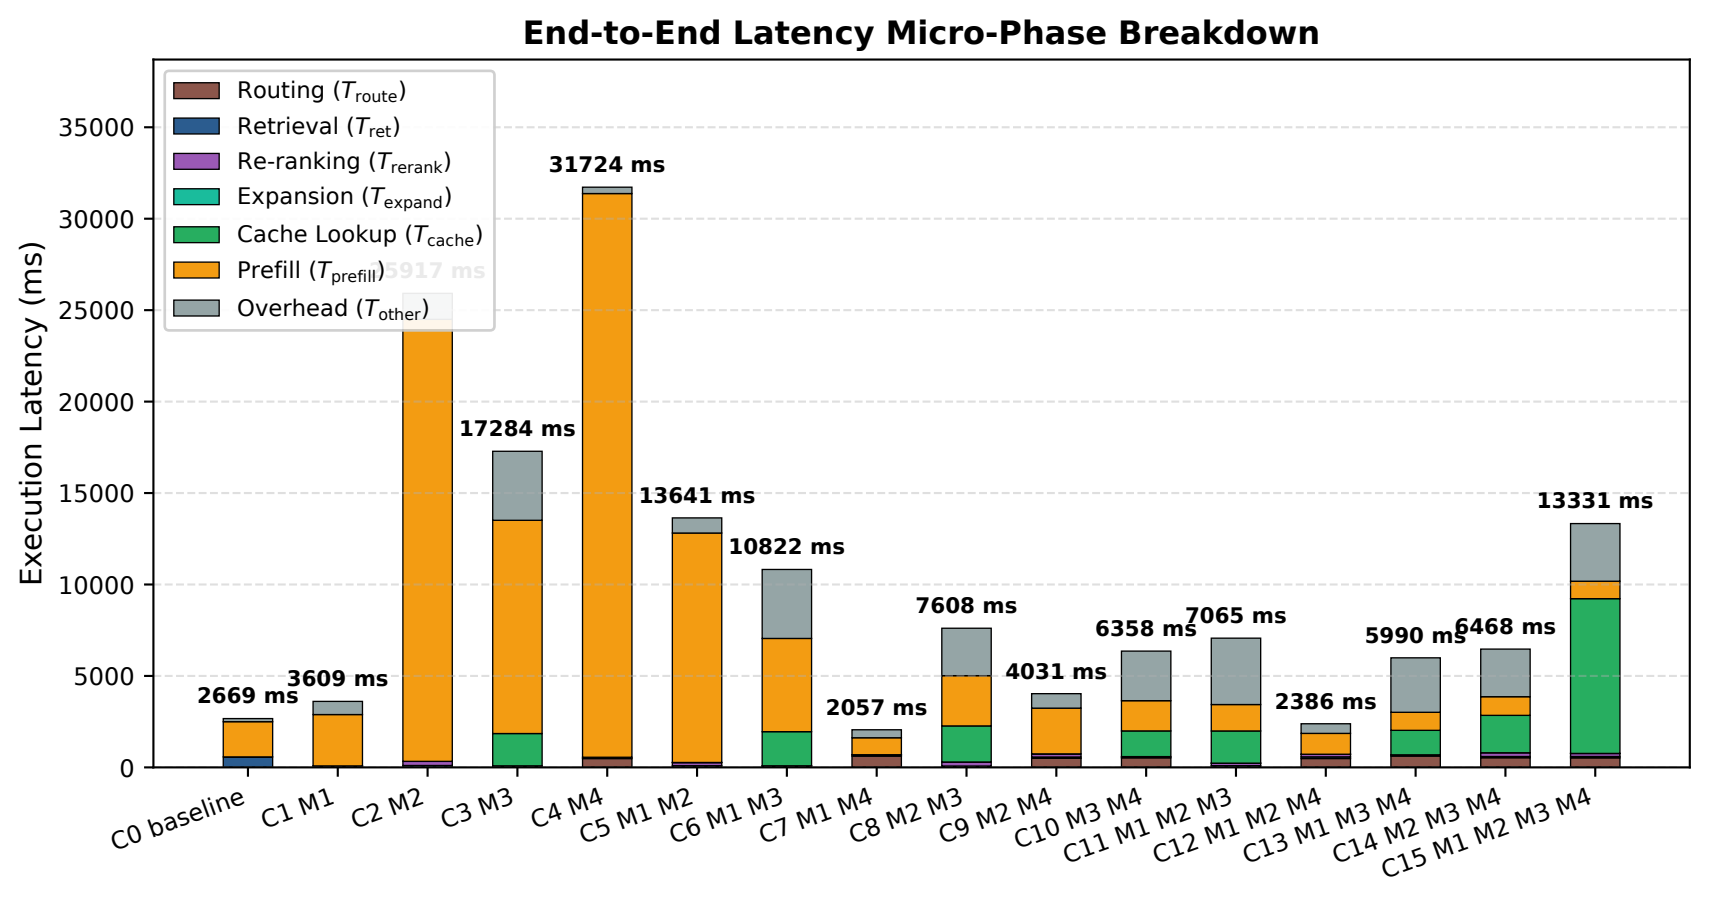
End-to-End Latency Micro-Phase Breakdown
Routing (T_{route})
Retrieval (T_{ret})
Re-ranking (T_{rerank})
Expansion (T_{expand})
Cache Lookup (T_{cache})
Prefill ($T_{prefill}$)
Overhead (T_{other})
Execution Latency (ms)
0
5000
10000
15000
20000
25000
30000
35000
2669 ms
3609 ms
26917 ms
17284 ms
31724 ms
13641 ms
10822 ms
2057 ms
7608 ms
4031 ms
6358 ms
7065 ms
2386 ms
5990 ms
6468 ms
13331 ms
C0 baseline
C1 M1
C2 M2
C3 M3
C4 M4
C5 M1 M2
C6 M1 M3
C7 M1 M4
C8 M2 M3
C9 M2 M4
C10 M3 M4
C11 M1 M2 M3
C12 M1 M2 M4
C13 M1 M3 M4
C14 M2 M3 M4
C15 M1 M2 M3 M4